



Program Studi Bioinformatika
FMIPA IPB University

Modul Praktikum Sistem Basis Data Bioinformatika

Pertemuan 7

Pencarian Data Biologis dan Penghubungan Hasil
dengan Basis Data Lokal

Prof. Dr. Eng. Wisnu Ananta Kusuma, S.T., M.T.
Dr. Luthfan Irfana, S.Si., M.Si.
Lailan Sahrina, Hasibuan, S.Kom., M.Kom.
Gilland Fausta Putra Achyar, S.Mat., M.Kom.
Said Thaufik Rizaldi, S.Kom., M.Kom.
Hakim Ilyas Azhar
Tsabitha Naylasafa Aurora

Daftar Isi

1	Pendahuluan	1
2	Bekal dan Persiapan Praktikum	1
2.1	Memahami Rekaman yang Akan Dihubungkan	1
2.2	Mengenali Format FASTA	2
2.3	Menyiapkan Database dan Berkas Kerja	2
3	Membaca Profil dalam Database Lokal	3
3.1	Memeriksa Database dan Identifier	3
3.2	Membaca Fitur dan Koordinat	3
3.3	Membaca Anotasi Lokal	4
4	Menelusuri Rekaman dan Mengambil Sekuens Protein	5
4.1	Menemukan Rekaman Gen	5
4.2	Memeriksa Hubungan Gen–Transkrip–Protein	5
4.3	Mengunduh dan Memeriksa FASTA Protein	6
5	Menjalankan dan Membaca BLASTP	7
5.1	Memasukkan Query dan Menentukan Target Pencarian	7
5.2	Mengatur dan Mendokumentasikan Parameter	8
5.3	Membaca Ringkasan Hit	9
5.4	Memeriksa Alignment Pertama	10
5.5	Menyimpan Hasil Pencarian	10
6	Memeriksa Konteks Genom dan Menelusuri Lokasi dengan BLAT	11
6.1	Membuka Konteks Gen pada Ensembl	11
6.2	Membandingkan Fitur Lokal dan Daring	12
6.3	Menelusuri Lokasi Sekuens dengan BLAT	12
7	Menyimpan dan Menghubungkan Hasil pada PostgreSQL	14
7.1	Membuat Tabel Rekaman Pencarian	14
7.2	Mengisi dan Memvalidasi Rekaman BLASTP	15
7.3	Mengisi dan Memvalidasi Pemeriksaan Repositori	17
7.4	Menguji Hubungan dengan Data Lokal	18
8	Lembar Kerja Praktikum (LKP)	20
8.1	Penelusuran Kolaboratif	20
8.2	Pertanyaan Pembahasan	20
8.3	Struktur, Format, dan Pengumpulan LKP	21

Tujuan Praktikum

1. Menelusuri hubungan antara *identifier* gen lokal dan rekaman gen, transkrip, serta protein pada repositori biologis.
2. Mengambil dan memverifikasi sekuens protein dalam format FASTA sebagai masukan pencarian.
3. Menjalankan BLASTP, membaca ukuran kemiripan sekuens, dan memeriksa konteks fitur melalui *genome browser*.
4. Menyimpan sumber dan hasil pencarian dalam PostgreSQL, lalu menghubungkannya dengan data lokal menggunakan SQL.

1 Pendahuluan

Database hasil Pertemuan 5 menyimpan profil gen dan fitur genomik sebagai salinan data pada suatu keadaan tertentu. Rekaman pada repositori daring dapat memiliki *identifier*, versi anotasi, atau informasi yang lebih baru. Karena itu, hubungan antara data lokal dan rekaman daring perlu diperiksa menggunakan sumber dan bukti yang dapat ditelusuri.

Pada praktikum ini, satu *identifier* gen lokal ditelusuri ke rekaman gen, transkrip, dan protein. Sekuens protein diambil dalam format FASTA, digunakan sebagai *query* BLASTP, lalu konteks genomiknya diperiksa melalui *genome browser*. Sumber, parameter, hasil pencarian, dan status pemeriksaan disimpan pada schema *mg07* di PostgreSQL dan dihubungkan kembali dengan data lokal menggunakan JOIN.

Pertanyaan Utama

Bagaimana rekaman lokal dapat dihubungkan dengan informasi pada repositori biologis menggunakan bukti yang dapat diperiksa dan ditelusuri kembali?

Kegiatan ini memenuhi Sub-CPMK7, yaitu melakukan *identifier mapping* dan menggabungkan data dari lebih dari satu sumber dengan pemeriksaan konsistensi. Produk praktikum berupa dokumentasi pemetaan, arsip hasil pencarian, dataset hasil pencatatan pada PostgreSQL, naskah SQL, dan Lembar Kerja Praktikum (LKP).

2 Bekal dan Persiapan Praktikum

2.1 Memahami Rekaman yang Akan Dihubungkan

Database lokal menyimpan *snapshot*, yaitu salinan data pada suatu keadaan tertentu. Repositori daring dapat menggunakan versi anotasi yang berbeda atau lebih baru. Perbedaan yang ditemukan perlu dicatat dan diperiksa terlebih dahulu sebelum dinilai sebagai kesalahan.

Istilah yang digunakan selama praktikum dirangkum pada Tabel 1.

Tabel 1. Istilah yang digunakan dalam Praktikum 07.

Istilah	Makna dalam kegiatan ini
<i>Identifier</i> gen	Label rekaman gen. Tabel gene masih dapat memuat alias yang belum dipetakan.

Tabel 1. Istilah yang digunakan dalam Praktikum 07 (lanjutan).

Istilah	Makna dalam kegiatan ini
Transkrip	Produk RNA dari suatu gen. <i>Identifier</i> transkrip dapat berbeda dari <i>identifier</i> gen.
CDS	Bagian pengode protein pada transkrip; di genom dapat tersusun atas beberapa segmen.
Protein	Rangkaian asam amino. Sekuens protein digunakan sebagai <i>query</i> BLASTP.
<i>Accession</i> dan versi	Pengenal rekaman pada repositori dan, jika tersedia, penanda versinya.
<i>Query</i> dan <i>hit</i>	<i>Query</i> adalah masukan pencarian; <i>hit</i> adalah rekaman yang mempunyai bagian sekuens serupa.
<i>Assembly</i> dan anotasi	<i>Assembly</i> adalah susunan sekuens genom; anotasi menunjukkan fitur yang ditempatkan pada genom tersebut.
<i>Strand</i>	Orientasi fitur terhadap sekuens referensi, ditulis + atau –.

2.2 Mengenali Format FASTA

FASTA mempunyai baris judul yang diawali tanda >, diikuti satu atau beberapa baris sekuens. Pada FASTA protein, huruf pada baris sekuens mewakili asam amino.

```
>accession deskripsi protein
MKT...
```

Simpan berkas FASTA asli dan pertahankan judul serta *accession* dari sumbernya. Nilai *start_pos* dan *end_pos* pada database lokal merupakan koordinat, bukan sekuens. Oleh karena itu, rekaman repositori perlu dibuka dan sekuens proteinnya diambil sebelum BLASTP dijalankan.

2.3 Menyiapkan Database dan Berkas Kerja

Persiapan Database

Siapkan database hasil *restore* Pertemuan 5, yaitu **biosqlite_mg05**. Nama database aktif akan diperiksa pada bagian berikutnya menggunakan **current_database()**. Jika database Pertemuan 5 sudah tidak tersedia, lakukan *restore* sebelum praktikum.

Siapkan lingkungan kerja dengan langkah berikut.

1. Pastikan server PostgreSQL dapat dihubungkan melalui pgAdmin.
2. Buat folder **NIM_nama_p07** untuk menyimpan seluruh berkas kegiatan.
3. Buat **NIM_nama_p07.sql** untuk menyimpan seluruh *query* praktikum.
4. Buka editor teks, lalu buat **catatan_p07.txt** untuk mencatat sumber, tanggal akses, *identifier*, parameter pencarian, dan nama berkas bukti.
5. Gunakan PF3D7_1145400 sebagai *identifier* utama.

Diskusi Awal

1. Apakah *identifier* gen harus sama dengan *accession* protein?

2. Mengapa pencarian menggunakan *identifier* berbeda dari pencarian menggunakan sekuens?

3 Membaca Profil dalam Database Lokal

Sebelum menelusuri repositori daring, periksa rekaman yang tersedia dalam database lokal. Tahap ini menetapkan profil awal yang nantinya dibandingkan dengan hasil penelusuran daring.

3.1 Memeriksa Database dan Identifier


Buka pgAdmin, hubungkan server PostgreSQL, lalu pilih database hasil *restore* Pertemuan 5. Buka **Query Tool** dan simpan naskah kerja sebagai *NIM_nama_p07.sql*. Jalankan kedua query berikut secara terpisah.

```
SELECT current_database();

SELECT gene_id
FROM public.gene
WHERE gene_id = 'PF3D7_1145400';
```

Query pertama memastikan bahwa Query Tool terhubung ke database yang benar. Query kedua harus menghasilkan satu baris PF3D7_1145400. Jika hasilnya kosong, periksa kembali database yang dipilih.

Contoh hasil pemeriksaan awal ditunjukkan pada Gambar 1.



Gambar 1. Pemeriksaan database aktif dan ketersediaan PF3D7_1145400.

3.2 Membaca Fitur dan Koordinat

Jalankan query berikut untuk membaca fitur yang berhubungan dengan PF3D7_1145400.

```
SELECT feature_id, gene_id, seqid, feature_type,
       start_pos, end_pos, strand
FROM public.gene_feature
WHERE gene_id = 'PF3D7_1145400'
ORDER BY feature_type, start_pos;
```

Satu *identifier* dapat menghasilkan beberapa baris karena gen, mRNA, exon, dan CDS merupakan fitur yang berbeda. Catat koordinat *protein_coding_gene* secara terpisah dari koordinat exon dan CDS. Nilai *start_pos* tetap lebih kecil daripada *end_pos* meskipun *strand* bernilai -.

Contoh hasil query fitur lokal ditunjukkan pada Gambar 2.

Query

```
SELECT feature_id, gene_id, seqid, feature_type,
       start_pos, end_pos, strand
FROM public.gene_feature
WHERE gene_id = 'PF3D7_1145400'
ORDER BY feature_type, start_pos;
```

Data Output

	feature_id [PK] integer	gene_id text	seqid text	feature_type text	start_pos integer	end_pos integer	strand text
1	30509	PF3D7_1145400	PF3D7_11_v3	CDS	1800544	1800570	-
2	30510	PF3D7_1145400	PF3D7_11_v3	CDS	1800735	1800781	-
3	30511	PF3D7_1145400	PF3D7_11_v3	CDS	1800929	1801065	-
4	30512	PF3D7_1145400	PF3D7_11_v3	CDS	1801248	1803550	-
5	30505	PF3D7_1145400	PF3D7_11_v3	exon	1800111	1800570	-
6	30506	PF3D7_1145400	PF3D7_11_v3	exon	1800735	1800781	-
7	30507	PF3D7_1145400	PF3D7_11_v3	exon	1800929	1801065	-
8	30508	PF3D7_1145400	PF3D7_11_v3	exon	1801248	1804509	-
9	30504	PF3D7_1145400	PF3D7_11_v3	mRNA	1800111	1804509	-
10	30503	PF3D7_1145400	PF3D7_11_v3	protein_coding_gene	1800111	1804509	-

Total rows: 10 Query complete 00:00:00.152

Gambar 2. Fitur dan koordinat lokal untuk PF3D7_1145400.

Pada database praktikum, query menghasilkan sepuluh baris: empat CDS, empat exon, satu mRNA, dan satu `protein_coding_gene`. Seluruh fitur berada pada `Pf3D7_11_v3` dengan `strand` - . Rentang `protein_coding_gene` adalah 1800111--1804509.

Ekspor hasil melalui tombol unduh pada **Data Output**, kemudian simpan sebagai `NIM_nama_p07_fitur_lokal.csv`.

3.3 Membaca Anotasi Lokal

Jalankan query berikut untuk membaca anotasi yang tersedia pada snapshot lokal.

```
SELECT gene_id, gene_symbol, go_id, qualifier,
       evidence_code, gene_product_name
FROM public.go_annotation
WHERE gene_id = 'PF3D7_1145400'
ORDER BY go_id
LIMIT 10;
```

Contoh anotasi lokal yang ditemukan ditunjukkan pada Gambar 3.

Query

```
SELECT gene_id, gene_symbol, go_id, qualifier,
       evidence_code, gene_product_name
FROM public.go_annotation
WHERE gene_id = 'PF3D7_1145400'
ORDER BY go_id
LIMIT 10;
```

Data Output

	gene_id text	gene_symbol text	go_id text	qualifier text	evidence_code text	gene_product_name text
1	PF3D7_1145400	DYN1	GO:0003723	[null]	HDA	dynam-in-like protein
2	PF3D7_1145400	DYN1	GO:0005634	[null]	HDA	dynam-in-like protein
3	PF3D7_1145400	DYN1	GO:0005634	[null]	HDA	dynam-in-like protein
4	PF3D7_1145400	DYN1	GO:0005737	[null]	IDA	dynam-in-like protein
5	PF3D7_1145400	DYN1	GO:0005886	[null]	IDA	dynam-in-like protein
6	PF3D7_1145400	DYN1	GO:0020005	[null]	IDA	dynam-in-like protein
7	PF3D7_1145400	DYN1	GO:0020020	[null]	IDA	dynam-in-like protein
8	PF3D7_1145400	DYN1	GO:0030430	[null]	IDA	dynam-in-like protein
9	PF3D7_1145400	DYN1	GO:0031965	[null]	IDA	dynam-in-like protein

Total rows: 9 Query complete 00:00:00.142

Gambar 3. Anotasi lokal untuk PF3D7_1145400.

Pilih satu baris hasil, lalu catat `go_id`, `evidence_code`, dan `qualifier` pada `catatan_p07.txt`. Jika `qualifier` kosong, tuliskan NULL. Jika `qualifier` memuat NOT, jangan membacanya sebagai dukungan positif terhadap anotasi. Jika query tidak menghasilkan baris, tuliskan “tidak ditemukan pada tabel lokal”.

Titik Pemeriksaan

Pastikan PF3D7_1145400 ditemukan satu kali pada tabel **gene**, hasil fitur telah disimpan sebagai CSV, satu anotasi lokal telah dicatat, dan seluruh query tersimpan dalam NIM_nama_p07.sql sebelum melanjutkan ke repositori daring.

4 Menelusuri Rekaman dan Mengambil Sekuens Protein

Gunakan satu repositori untuk mengambil protein dan memeriksa hubungan antara gen, transkrip, dan protein. Pada kegiatan ini, Ensembl digunakan sebagai sumber utama. Label menu dapat berubah antarrilis, tetapi rekaman yang dicari tetap berupa rekaman gen, tabel transkrip, dan sekuens protein.


4.1 Menemukan Rekaman Gen

Biarkan pgAdmin tetap terbuka agar hasil repositori dapat dibandingkan dengan profil lokal. Buka <https://www.ensembl.org>, kemudian lakukan langkah berikut.

1. Buka **Genome selector**, lalu cari *Plasmodium falciparum*.
2. Pilih *Plasmodium falciparum* 3D7 dengan assembly **GCA_000002765.3**.
3. Cari PF3D7_1145400, lalu buka hasil bertipe **Gene** dengan simbol DYN1.
4. Periksa *identifier*, organisme, assembly, lokasi, dan arah *strand*. Salin URL rekaman serta tanggal akses ke **catatan_p07.txt**.

Rekaman yang benar menunjukkan simbol DYN1 dan gen PF3D7_1145400. Assembly yang dipilih adalah GCA_000002765.3. Gen berada pada rentang 1800111--1804509 di *reverse strand*. Hasil tersebut sesuai dengan fitur **protein_coding_gene** pada database lokal.

Tampilan rekaman gen pada Ensembl ditunjukkan pada Gambar 4.



Gambar 4. Rekaman PF3D7_1145400 pada Ensembl.

4.2 Memeriksa Hubungan Gen–Transkrip–Protein

Buka **Feature Explorer**, pilih **Transcripts** table, lalu buka produk protein dari transkrip yang memiliki translasi. Jika suatu gen memiliki lebih dari satu transkrip, catat transkrip yang dipilih


dan gunakan pilihan yang sama pada seluruh kegiatan.
Pada rilis yang digunakan dalam praktikum ini, hubungan identifier yang diharapkan dirangkum pada Tabel 2.

Tabel 2. Hubungan identifier gen, transkrip, dan protein yang digunakan.

Komponen	Identifier atau nilai
Gen	PF3D7_1145400 (DYN1)
Transkrip	PF3D7_1145400.1
Protein/translation	PF3D7_1145400.1-p1
Panjang protein	837 asam amino
Cross-reference	UniProtKB/TrEMBL Q8IHR4; Q9BJC6

Rentang genomik transkrip, panjang cDNA, dan panjang protein mengukur hal yang berbeda. Rentang genomik mencakup intron, cDNA tersusun dari exon setelah *splicing*, sedangkan panjang protein dihitung dalam residu asam amino. Oleh karena itu, nilai 4399 bp, 3906 bp, dan 837 aa tidak saling bertentangan.

Hubungan gen, transkrip, dan produk protein ditunjukkan pada Gambar 5.



Gambar 5. Hubungan gen, transkrip, dan produk protein pada Ensembl.


Hubungan tersebut terlihat pada satu halaman **Feature Explorer**: panel kanan menampilkan gen DYN1/PF3D7_1145400, bagian atas menampilkan transkrip PF3D7_1145400.1, dan panel **Protein** menampilkan PF3D7_1145400.1-p1 beserta panjang 837 asam amino. Catat *identifier* gen, transkrip, protein, panjang protein, *cross-reference*, URL, dan tanggal akses pada catatan_p07.txt.

4.3 Mengunduh dan Memeriksa FASTA Protein

Pada panel protein, pilih hanya **Protein sequence**. Jangan memilih **CDS** karena BLASTP memerlukan sekuens asam amino, bukan sekuens nukleotida. Klik **Download**, kemudian simpan berkas sebagai PF3D7_1145400.protein.fasta.

Buka berkas dengan editor teks. Pastikan berkas memuat satu judul yang diawali karakter > dan baris sekuens protein di bawahnya seperti pada Gambar 6.

Pertahankan judul, versi *identifier*, dan isi sekuens seperti yang diberikan oleh sumber. Jangan menghapus akhiran .1, mengganti *identifier*, atau menyalin sekuens dari tampilan lain. Berkas yang benar memuat satu sekuens sepanjang 837 asam amino.



```
>PF3D7_1145400.1-p1 pep
METSNNLRKLLNVIDELRDGLQKYINLPRICVGTQSSGKSSVLESTVGMDFLRGE
GIVTRRPIERLZHIKEDESEKYNVAFENEKKNKYTFNEVREQINRLTDEIAGKNGII
DEPIVLNIZSIKCPDLSIDLPGITRVPLKNSQTDTERLTRDMALRYVKDPTIILAV
LPANADMTSDALQIARKVDPKGLRTIGVTTKIDLMKGADASKMLNDEINLRGVTGV
VNRSTADIKKGTISQALKDELEFFQKHPYVKLLPPALYGTNLSLTKLVLLRHKNFL
PDKIEIHKERYTNDKLYELGTNPLDATKTQLKSHETDYCEFFNTLKGKVKRQVQ
VFIEINDILCGLKVRTIFNEFLDEVGKINVTSELTNDIDDAICLHEGDSLPGFSPOTF
EFLILPHLKKINAPVFNCLDRVSQTEILSQIANRVLNRPFKLSEQVLELSQTLIREK
ENTQILENYDAETHYLFNDASYLIEHGSINAADDEHNNNTTNNNNNNNNSS
SYDYGQHRQKQKQSHSNSSQDTLLSTSKYSYSHMSQGEYNTGAKAPVTSAGKS
VMNIMNTEKKTRYNAQFIQIRRLDCYFNILNHRVDSVPKMGIVFLRKLEKQNF
EYSDLNSQKLYDLLNEPPHVVKEHELNQLEIKKANQVLLKDPNITSINLDLFDAN
YEQDLMDYQKSLKNTNFQNSKHPNHSQSSANSHMYLNDGSSSHSKRNPNNHNRNPS
PSSNNTNPKQTNHGLQKQKHSPPSSYYQGHQPHNDKGRHLFEKPKKKVNYNPLFD
```

Gambar 6. Berkas FASTA protein PF3D7_1145400.1-p1.

Jika Rekaman Tidak Langsung Ditemukan

Periksa kembali ejaan *identifier*, organisme, dan assembly. Jika Ensembl tidak dapat digunakan, buka NCBI Protein melalui <https://www.ncbi.nlm.nih.gov/protein/>, lalu cari PF3D7_1145400 bersama nama organisme. Gunakan rekaman tersebut hanya jika hubungannya dengan gen dapat ditunjukkan melalui anotasi atau *cross-reference*. Catat sumber alternatif yang benar-benar digunakan.

Titik Pemeriksaan

Tunjukkan kepada rekan praktikum halaman yang mendukung hubungan PF3D7_1145400 dengan produk proteinnya dan baris judul FASTA. Pastikan PF3D7_1145400_protein.fasta memuat protein PF3D7_1145400.1-p1 sepanjang 837 asam amino sebelum melanjutkan ke BLASTP.

5 Menjalankan dan Membaca BLASTP

BLASTP membandingkan sekuens protein yang telah diambil dari Ensembl dengan sekuens pada database protein NCBI. Pencarian dilakukan menggunakan sekuens FASTA, bukan hanya dengan mengetikkan *identifier* gen.

5.1 Memasukkan Query dan Menentukan Target Pencarian

Buka halaman **Standard Protein BLAST** melalui <https://blast.ncbi.nlm.nih.gov/Blast.cgi?PAGE=Proteins>, kemudian lakukan langkah berikut.

1. Pada bagian **Enter Query Sequence**, unggah PF3D7_1145400_protein.fasta. Seluruh isi FASTA juga dapat ditempelkan pada kotak query. Jangan mengganti sekuens protein dengan *identifier* gen.
2. Isi **Job Title** dengan NIM_p07_PF3D7_1145400. Ganti NIM dengan NIM masing-masing ketika mengerjakan praktikum.
3. Pilih **Reference proteins (refseq_protein)** pada bagian **Database**.
4. Ketik *Plasmodium falciparum* pada bagian **Organism**, kemudian pilih *Plasmodium falciparum* (taxid:5833) dari daftar yang ditawarkan. Biarkan kotak **exclude** tidak dicentang.

- Pilih algoritma **blastp** (protein-protein BLAST). Biarkan **Align two or more sequences** tidak dicentang.

Pengaturan umum yang benar ditunjukkan pada Gambar 7.

Standard Protein BLAST

BLASTP programs search protein databases using a protein query. more...

Enter Query Sequence

Enter accession number(s), gi(s), or FASTA sequence(s) Clear

Query subrange From To

Or, upload file Choose File (PF3D7_114...protein.fasta) ?

Job Title NIM_p07_Pf3D7_1145400

Enter a descriptive title for your BLAST search ?

☐ Align two or more sequences ?

Choose Search Set

Database Reference proteins (refseq_protein) ?

Organism Plasmodium falciparum (taxid 5833) exclude Add organism

Optional Enter organism common name, binomial, or tax id. Only 20 top taxa will be shown. ?

Exclude Models (MMXP) Non-redundant RefSeq proteins (WP) Uncultured/environmental sample sequences

Optional

Program Selection

Algorithm ☒ blastp (protein-protein BLAST)

☐ PSI-BLAST (Position-Specific Iterated BLAST)

☐ PHI-BLAST (Pattern Hit Initiated BLAST)

☐ DELTA-BLAST (Domain Enhanced Lookup Time Accelerated BLAST)

Choose a BLAST algorithm ?

Gambar 7. Pengaturan query, database, organisme, dan algoritma BLASTP.

5.2 Mengatur dan Mendokumentasikan Parameter

Buka bagian **Algorithm parameters**. Tetapkan **Max target sequences** menjadi 10 dan **Expect threshold** menjadi 0.001. Gunakan matriks BLOSUM62, *gap costs* Existence 11 dan Extension 1, serta **Conditional compositional score matrix adjustment**. Pastikan **Low-complexity filter**, **Mask for lookup table only**, dan **Mask lower-case letters** tidak dicentang. Biarkan parameter lainnya pada nilai yang ditampilkan NCBI. Pengaturan tersebut ditunjukkan pada Gambar 8.

Note: Parameter values that differ from the default are highlighted in yellow and marked with a sign

Algorithm parameters

General Parameters

Max target sequences 10

Select the maximum number of aligned sequences to display ?

Short queries ☒ Automatically adjust parameters for short input sequences ?

Expect threshold 0.001

Word size 5

Max matches in a query range 0

Scoring Parameters

Matrix BLOSUM62 ?

Gap Costs Existence: 11 Extension: 1 ?

Compositional adjustments Conditional compositional score matrix adjustment ?

Filters and Masking

Filter ☐ Low complexity regions ?

Mask ☐ Mask for lookup table only ?

☐ Mask lower-case letters ?

BLAST

Search database refseq_protein using Blastp (protein-protein BLAST)

☐ show results in a new window

Gambar 8. Parameter algoritma yang digunakan untuk pencarian BLASTP.

Periksa kembali query, database, organisme, dan seluruh parameter sebelum menekan **BLAST**. Setelah pencarian dikirim, catat waktu pencarian dan RID yang diberikan NCBI pada `catatan_p07.txt`. RID bukan pengganti arsip hasil karena memiliki masa simpan terbatas.

Setelah hasil terbuka, pilih **Search Summary**. Pastikan parameter yang benar-benar digunakan server sesuai dengan pengaturan sebelumnya seperti pada Gambar 9. Simpan ringkasan parameter aktual sebagai bukti tambahan.

← Edit Search	Save Search	Search Summary ▼
-------------------------------	-----------------------------	----------------------------------

Search Parameters	
Program	blastp
Word size	5
Expect value	0.001
Hitlist size	10
Gapcosts	11,1
Matrix	BLOSUM62
Filter string	F
Genetic Code	1
Window Size	40
Threshold	0
Composition-based stats	2

Database	
Posted date	Oct 1, 2026 4:23 AM
Number of letters	4,098,806
Number of sequences	5,377
Entrez query	Includes: Plasmodium falciparum (taxid:5833)

Karlin-Altschul statistics		
Lambda	0.315137	0.267
K	0.132639	0.041
H	0.371979	0.14
Alpha	0.7916	1.9
Alpha_v	4.96466	42.6028
Sigma		43.6362

Results Statistics	
--------------------	--

Gambar 9. Ringkasan parameter BLASTP yang digunakan oleh server.

5.3 Membaca Ringkasan Hit

Buka tab **Descriptions**. Catat paling banyak tiga hit sesuai urutan yang ditampilkan. Jika tidak ada hit, dokumentasikan bahwa pencarian tidak menghasilkan kecocokan pada pengaturan yang digunakan.

Gunakan kolom-kolom berikut ketika membaca hasil.

- Percent identity** Persentase residu identik di dalam bagian yang dialignkan. Nilai ini tidak selalu mewakili seluruh panjang protein.
- Query cover** Persentase panjang query yang tercakup oleh alignment.
- E-value** Perkiraan banyaknya kecocokan dengan skor sama atau lebih baik yang dapat muncul secara kebetulan. Nilai yang semakin kecil menunjukkan dukungan statistik yang semakin kuat.
- Max score** Skor bit tertinggi dari satu bagian alignment. Nilai ini berbeda dari **Total score**, yang menjumlahkan skor seluruh bagian alignment untuk satu subject.

Pada saat modul ini diverifikasi, pencarian menghasilkan dua hit seperti ditunjukkan pada Gambar 10. Isi database NCBI dapat diperbarui sehingga jumlah hit atau nilai numeriknya dapat berubah. Gunakan hasil yang benar-benar ditampilkan pada saat praktikum.

Descriptions		Graphic Summary	Alignments	Taxonomy
Sequences producing significant alignments				
☒ select all 2 sequences selected		Download ▼ Select columns ▼ Show 10 ▼		
		GenPept Graphics Distance tree of results Multiple alignment MSA Viewer		
Description ▼	Scientific Name ▼	Max Score ▼	Total Score ▼	Query Cover ▼
☒ dynamin family protein [Plasmodium falciparum:3D7]	Plasmodium falciparum:3D7	1718	1718	100%
☒ dynamin family protein [Plasmodium falciparum:3D7]	Plasmodium falciparum:3D7	251	251	83%

FOLLOW NCBI

Gambar 10. Protein yang menghasilkan alignment signifikan pada BLASTP.

Kemiripan sekuens tidak dengan sendirinya membuktikan bahwa dua protein memiliki fungsi yang identik. Nilai identity yang tinggi dengan query cover yang rendah hanya menunjukkan kemiripan pada sebagian query. Hit berupa protein yang sama juga dapat muncul ketika database memuat rekaman protein query. Tampilan E-value 0.0 merupakan pembulatan untuk nilai yang sangat kecil, bukan peluang yang secara matematis tepat sama dengan nol.

5.4 Memeriksa Alignment Pertama

Pilih tab **Alignments**, lalu buka hit pertama. Periksa accession, rentang query dan subject, skor, E-value, identities, positives, serta gaps. Pada hasil yang diverifikasi, protein Ensembl PF3D7_1145400.1-p1 memiliki alignment sepanjang 837 residu dengan protein RefSeq XP_001348132.1, dengan skor 1718 bits (4450), E-value 0.0, identities dan positives sebesar 837/837 (100%), serta gaps 0/837 (0%). Detail hasil tersebut ditunjukkan pada Gambar 11. Simpan tangkapan layar yang memperlihatkan accession, statistik alignment, dan awal pasangan sekuens.

The screenshot shows the BLASTP results for a query protein. The top section includes links for Download, GenPept, and Graphics. Below this, the query is identified as 'dynamain family protein [Plasmodium falciparum 3D7]' with sequence ID 'XP_001348132.1' and length 837. The alignment statistics show a score of 1718 bits (4450), an expect value of 0.0, and 100% identity and positives. The alignment itself is shown in a table with columns for Score, Expect, Method, Identities, Positives, and Gaps. The query and subject sequences are aligned perfectly, with no gaps.

Score	Expect	Method	Identities	Positives	Gaps
1718 bits(4450)	0.0	Compositional matrix adjust.	837/837(100%)	837/837(100%)	0/837(0%)

Range 1: 1 to 837

Query	Subject	Score
1	1	60
61	61	120
121	121	180
181	181	240
241	241	300
361	361	360
420	420	420

Related Information: Gene - associated gene details, AlphaFold Structure - 3D structure displays, Genome Data Viewer - aligned genomic context

Gambar 11. Alignment identik antara query dan hit pertama BLASTP.

5.5 Menyimpan Hasil Pencarian

Buka menu **Download All**, kemudian simpan keluaran yang tercantum pada Tabel 3 di dalam folder NIM>Nama_P07.

Tabel 3. Berkas hasil BLASTP yang disimpan.

Pilihan menu	Nama berkas	Kegunaan
Text	NIM_nama_p07_blastp.txt	laporan yang mudah dibaca
Hit Table(csv)	NIM_nama_p07_hit.csv	tabel alignment
Single-file XML2	NIM_nama_p07_blastp.xml	arsip terstruktur

Simpan juga halaman hasil melalui **Print** atau **Ctrl+P**, pilih **Save as PDF**, lalu gunakan nama NIM_nama_p07_blastp.pdf. Berkas XML dipakai sebagai arsip terstruktur; mahasiswa tidak perlu membacanya secara manual.

Tabel CSV dapat memuat lebih banyak baris daripada jumlah protein pada tab **Descriptions**. Satu protein dapat mempunyai lebih dari satu *high-scoring segment pair* (HSP), dan setiap HSP dapat ditulis sebagai baris terpisah. Ketika mengisi ringkasan hit, gunakan maksimum tiga protein

pada tab **Descriptions**, bukan tiga baris pertama CSV tanpa memeriksa accession. Catat nama berkas, RID, waktu pencarian, database, pembatas organisme, dan jumlah hit pada `catatan_p07.txt`.

Titik Pemeriksaan

Pastikan pengaturan umum dan parameter BLASTP telah didokumentasikan, parameter aktual pada **Search Summary** telah diperiksa, maksimum tiga hit telah dicatat, serta alignment pertama telah dibuka.

6 Memeriksa Konteks Genom dan Menelusuri Lokasi dengan BLAT

Genome browser menempatkan fitur pada sekuens referensi sehingga hubungan posisi gen, transkrip, ekson, dan CDS dapat diperiksa. Pada bagian ini, hasil daring dibandingkan dengan fitur lokal yang telah dibaca pada bagian sebelumnya.


6.1 Membuka Konteks Gen pada Ensembl

Kembali ke rekaman gen PF3D7_1145400 pada Ensembl, lalu buka **Genome Browser**. Atur tampilan hingga struktur gen, identifier, dan koordinat dapat dibaca.

1. Pastikan organisme yang dipilih adalah *Plasmodium falciparum* 3D7 dan identifier gen yang ditampilkan adalah PF3D7_1145400.
2. Catat accession assembly dan rilis anotasi jika tersedia.
3. Catat region atau kromosom, posisi awal-akhir, dan strand.
4. Tentukan jenis fitur yang sedang dibaca, misalnya batas gen, transkrip, atau CDS.
5. Salin URL halaman dan catat tanggal akses pada `catatan_p07.txt`.

Pada saat modul ini diverifikasi, halaman Ensembl menampilkan assembly GCA_000002765.3, rilis 2026-07, region LN999945.1, dan gen PF3D7_1145400 pada koordinat 1,800,111--1,804,509 di strand negatif. Gunakan metadata yang ditampilkan pada saat praktikum apabila rilis Ensembl telah berubah.

Konteks genom gen pada Ensembl ditunjukkan pada Gambar 12.



Gambar 12. Konteks genom gen PF3D7_1145400 pada Ensembl Genome Browser.

Simpan tangkapan layar yang memperlihatkan identifier dan koordinat dengan nama PF3D7_1145400_browser.png.

6.2 Membandingkan Fitur Lokal dan Daring

Buka kembali hasil query fitur lokal pada pgAdmin. Bandingkan fitur `protein_coding_gene` dengan batas gen yang ditampilkan Ensembl. Jangan membandingkan batas CDS daring dengan batas seluruh gen lokal. Hasil pemeriksaan saat modul diverifikasi dirangkum pada Tabel 4.

Tabel 4. Perbandingan fitur gen lokal dan rekaman Ensembl saat modul diverifikasi.

Komponen	Database lokal	Ensembl
Identifier	PF3D7_1145400	PF3D7_1145400
Jenis fitur	<code>protein_coding_gene</code>	<i>protein-coding gene</i>
Seqid/region	Pf3D7_11_v3	LN999945.1
Posisi awal	1.800.111	1.800.111
Posisi akhir	1.804.509	1.804.509
Strand	-	<i>reverse strand</i>

Nama seqid lokal dan region daring dapat berbeda walaupun merujuk pada kromosom yang sama. Karena schema lokal tidak menyimpan versi assembly secara eksplisit, catat keterbatasan tersebut ketika menentukan status pemeriksaan. Untuk hasil pada Tabel 4, identifier, jenis fitur, koordinat, kromosom, dan strand yang teramati mendukung status **sesuai**.

Untuk interval 1-based inclusive, panjang rentang dihitung menggunakan

$$\text{panjang interval} = \text{posisi akhir} - \text{posisi awal} + 1.$$

Dengan demikian, panjang interval gen adalah

$$1.804.509 - 1.800.111 + 1 = 4.399 \text{ bp.}$$

Panjang interval gen tidak sama dengan panjang protein 837 asam amino karena wilayah genom dapat mencakup intron dan bagian yang tidak diterjemahkan.

6.3 Menelusuri Lokasi Sekuens dengan BLAT

BLAT digunakan untuk menelusuri lokasi sekuens protein pada genom target.


Buka UCSC Genome Browser untuk assembly GCF_000002765.6 melalui https://genome.ucsc.edu/h/GCF_000002765.6, lalu lakukan langkah berikut.

1. Pastikan header Genome Browser mencantumkan GCF_000002765.6, kemudian pilih **Tools > BLAT**.
2. Pada **Query type**, pilih **Protein**.
3. Biarkan **Sort output** pada **Query,score** dan **Output type** pada **Hyperlink**.
4. Pada bagian **File Upload**, pilih PF3D7_1145400_protein.fasta. Biarkan **All Results** dan **Optimize Display for Rearrangements** tidak dicentang.
5. Klik **Submit file**. Tombol **Submit** di dekat kotak sekuens digunakan apabila FASTA ditempel langsung ke kotak tersebut.

6. Pada tabel hasil, periksa query, skor, rentang query, ukuran query, identity, kromosom, strand, dan koordinat.
7. Buka **details** untuk membaca ringkasan alignment, kemudian kembali ke hasil dan buka **browser** untuk melihat track BLAT bersama anotasi gen.

Pada beberapa halaman, UCSC dapat menampilkan judul ringkas GCA_000002765 Apr. 2016. Periksa assembly aktif pada header Genome Browser. Assembly tersebut harus tercantum sebagai GCF_000002765.6.

Contoh hasil pencarian BLAT ditunjukkan pada Gambar 13.




ACTIONS	QUERY	SCORE	START	END	QSIZE	IDENTITY	CHROM	STRAND	START	END	SPAN
browser new_tab details	PF3D7_1145400.1-p1	2488	1	837	837	100.0%	NC_037282.1	-	1800732	1803550	2819

Gambar 13. Hasil pencarian lokasi protein PF3D7_1145400.1-p1 menggunakan BLAT.

Pada hasil BLAT yang diverifikasi, query PF3D7_1145400.1-p1 sepanjang 837 asam amino dipetakan ke kromosom NC_037282.1 pada koordinat 1.800.732–1.803.550. Alignment mencakup residu query 1–830 dalam tiga blok, dengan 830 dari 837 residu cocok dan identity 100,0%. Tanda strand +- menunjukkan bahwa query protein disejajarkan dengan genom pada strand negatif. Nilai tersebut merupakan hasil pengamatan pada BLAT dan tidak perlu dimasukkan sebagai parameter pencarian.

Tujuh residu terminal query tidak terpetakan pada hasil tersebut. Koordinat BLAT menunjukkan bagian pengode yang disejajarkan dan tidak menggantikan batas seluruh gen. Lokasi pada kromosom 11 dan arah strand negatif tetap konsisten dengan rekaman lokal dan tampilan Ensembl.

Kesesuaian track BLAT dengan anotasi gen ditunjukkan pada Gambar 14.



Gambar 14. Track BLAT dan anotasi PF3D7_1145400 pada UCSC Genome Browser.

Pertanyaan Pemantik

Berdasarkan hasil yang diamati, apa perbedaan informasi yang diberikan oleh BLASTP dan BLAT? Mengapa koordinat hasil BLAT tidak selalu sama dengan batas seluruh gen?

Titik Pemeriksaan

Pastikan jenis fitur lokal dan daring yang dibandingkan setara. Catat assembly, region atau kromosom, koordinat, strand, URL, tanggal akses, status pemeriksaan, serta bukti atau keterbatasan yang mendasari status tersebut.

7 Menyimpan dan Menghubungkan Hasil pada PostgreSQL

Tahap ini menyimpan metadata pencarian, ringkasan hit BLASTP, dan hasil pemeriksaan repositori pada schema `mg07`. Data tersebut dihubungkan dengan gen yang sudah tersedia pada `public.gene`; jangan menambahkan ulang PF3D7_1145400 ke tabel `public.gene`.

7.1 Membuat Tabel Rekaman Pencarian

Jalankan perintah berikut pada database yang sama dengan tabel `public.gene`. Tabel `search_run` menyimpan satu kegiatan pencarian, sedangkan `search_hit` menyimpan hit yang dipilih dari kegiatan tersebut.

```
CREATE SCHEMA IF NOT EXISTS mg07;

CREATE TABLE IF NOT EXISTS mg07.search_run (
    run_id text PRIMARY KEY,
    gene_id text NOT NULL
        REFERENCES public.gene(gene_id),
    query_accession text NOT NULL,
    source_url text NOT NULL,
    fasta_file text NOT NULL,
    program text NOT NULL,
    target_database text NOT NULL,
    organism_filter text,
    parameters_note text NOT NULL,
    searched_at timestamptz NOT NULL,
    result_file text NOT NULL,
    result_origin text NOT NULL
        CHECK (result_origin IN ('mandiri', 'cadangan'))
);

CREATE TABLE IF NOT EXISTS mg07.search_hit (
    run_id text NOT NULL
        REFERENCES mg07.search_run(run_id),
    hit_rank integer NOT NULL CHECK (hit_rank > 0),
    hit_accession text NOT NULL,
    hit_description text,
    organism text,
    percent_identity numeric
        CHECK (percent_identity BETWEEN 0 AND 100),
    query_cover numeric
        CHECK (query_cover BETWEEN 0 AND 100),
    evalue numeric CHECK (evalue >= 0),
```

```

max_bit_score numeric CHECK (max_bit_score >= 0),
PRIMARY KEY (run_id, hit_rank)
);

```

Berikutnya buat tabel untuk mencatat pemeriksaan antara rekaman lokal dan repositori daring.

```

CREATE TABLE IF NOT EXISTS mg07.repository_check (
  check_id text PRIMARY KEY,
  gene_id text NOT NULL
    REFERENCES public.gene(gene_id),
  external_gene_id text NOT NULL,
  assembly_note text NOT NULL,
  feature_type text NOT NULL,
  seqid text,
  start_pos integer CHECK (start_pos > 0),
  end_pos integer,
  strand text CHECK (strand IN ('+', '-')),
  source_url text NOT NULL,
  accessed_on date NOT NULL,
  match_status text NOT NULL
    CHECK (match_status IN
      ('sesuai', 'berbeda', 'belum_terverifikasi')),
  note text NOT NULL,
  CHECK (end_pos >= start_pos)
);

```

Segarkan bagian **Schemas** pada **Object Explorer**, lalu buka mg07 > **Tables**. Pastikan ketiga tabel terlihat. Jalankan query berikut sebagai pemeriksaan struktur.

```

SELECT table_name, COUNT(*) AS jumlah_kolom
FROM information_schema.columns
WHERE table_schema = 'mg07'
GROUP BY table_name
ORDER BY table_name;

```

Hasil yang diharapkan adalah **repository_check** sebanyak 13 kolom, **search_hit** sebanyak 9 kolom, dan **search_run** sebanyak 12 kolom. Angka tersebut menyatakan jumlah kolom, bukan jumlah data.

Tampilan ketiga tabel yang telah terbentuk ditunjukkan pada Gambar 15.



Gambar 15. Schema mg07 dan tiga tabel penyimpanan hasil praktikum.

7.2 Mengisi dan Memvalidasi Rekaman BLASTP

Pada **Object Explorer**, klik kanan mg07.search_run, pilih **View/Edit Data** > **All Rows**, lalu tambahkan satu baris. Masukkan nilai pada Tabel 5. Ganti bagian NIM, RID, serta waktu pencarian dengan data masing-masing; nilai lainnya diketik seperti yang tercantum pada tabel.

Tabel 5. Isian pada tabel `mg07.search_run`.

Kolom	Nilai yang dimasukkan
<code>run_id</code>	NIM_p07_01
<code>gene_id</code>	PF3D7_1145400
<code>query_accession</code>	PF3D7_1145400.1-p1
<code>source_url</code>	https://www.ensembl.org/genome-browser/GCA_000002765.3?focus=gene:PF3D7_1145400
<code>fasta_file</code>	PF3D7_1145400_protein.fasta
<code>program</code>	BLASTP
<code>target_database</code>	refseq-protein
<code>organism_filter</code>	Plasmodium falciparum (taxid:5833)
<code>parameters_note</code>	Max target sequences=10; Expect threshold=0.001; Matrix=BLOSUM62; Gap costs=11/1; compositional adjustment=conditional; low-complexity filter=off; mask for lookup table only=off; mask lower-case letters=off; RID= RID hasil masing-masing
<code>searched_at</code>	YYYY-MM-DD HH:MM:SS+07; ganti dengan waktu pencarian masing-masing
<code>result_file</code>	NIM_nama_p07_blastp.txt
<code>result_origin</code>	mandiri

Tekan **Save Data Changes**. Setelah itu, buka `mg07.search_hit` melalui menu yang sama. Untuk hasil yang digunakan pada modul ini, masukkan dua baris sesuai Tabel 6. Ganti bagian NIM dengan NIM masing-masing.

Tabel 6. Isian pada tabel `mg07.search_hit`.

Kolom	Hit 1	Hit 2
<code>run_id</code>	NIM_p07_01	NIM_p07_01
<code>hit_rank</code>	1	2
<code>hit_accession</code>	XP_001348132.1	XP_001347652.1
<code>hit_description</code>	dynamin family protein	dynamin family protein
<code>organism</code>	Plasmodium falciparum 3D7	Plasmodium falciparum 3D7
<code>percent_identity</code>	100.00	29.92
<code>query_cover</code>	100	83
<code>evaluate</code>	0	8e-73
<code>max_bit_score</code>	1718	251

Setelah kedua baris diisi, tekan **Save Data Changes**, kemudian jalankan query validasi berikut.


```
SELECT
  r.run_id,
  r.gene_id,
  h.hit_rank AS rank,
  h.hit_accession AS accession,
  h.percent_identity AS identity_pct,
  h.query_cover AS cover_pct,
```

```

CASE
  WHEN h.evalue = 0 THEN '0.0'
  ELSE TRIM(TO_CHAR(h.evalue, '9.99EEEE'))
END AS evalue,
h.max_bit_score AS max_score
FROM mg07.search_run AS r
LEFT JOIN mg07.search_hit AS h
  ON h.run_id = r.run_id
WHERE r.run_id = 'NIM_p07_01'
ORDER BY h.hit_rank;

```

Hasil harus memuat satu baris untuk setiap hit yang dicatat. Contoh hasil penyimpanan *run* dan hit ditunjukkan pada Gambar 16.



Gambar 16. Rekaman pencarian dan dua hit BLASTP yang tersimpan pada schema mg07.

7.3 Mengisi dan Memvalidasi Pemeriksaan Repositori

Buka mg07.repository_check melalui **View/Edit Data > All Rows**. Tambahkan satu baris berdasarkan perbandingan fitur lokal dan Ensembl pada bagian sebelumnya. Masukkan nilai pada Tabel 7. Ganti bagian NIM dan tanggal akses dengan data masing-masing; nilai lainnya diketik seperti yang tercantum pada tabel.

Tabel 7. Isian pada tabel mg07.repository_check.

Kolom	Nilai yang dimasukkan
check_id	NIM_p07_check01
gene_id	PF3D7_1145400
external_gene_id	PF3D7_1145400
assembly_note	Ensembl GCA_000002765.3; rilis 2026-07
feature_type	protein_coding_gene
seqid	LN999945.1
start_pos	1800111
end_pos	1804509
strand	-
source_url	https://www.ensembl.org/genome-browser/GCA_000002765.3?focus=gene:PF3D7_1145400&location=LN999945.1:1799500-1805100
accessed_on	YYYY-MM-DD; ganti dengan tanggal akses masing-masing
match_status	sesuai

Tabel 7. Isian pada tabel `mg07.repository_check` (lanjutan).

Kolom	Nilai yang dimasukkan
<code>note</code>	Identifier, jenis fitur, koordinat, dan strand sesuai; <code>seqid</code> lokal <code>Pf3D7_11.v3</code> ekuivalen dengan region Ensembl <code>LN999945.1</code> ; versi assembly lokal tidak tersimpan secara eksplisit.

Status `sesuai` harus didasarkan pada bukti, bukan hanya kesamaan identifier. Pada contoh ini, identifier, jenis fitur, koordinat, kromosom, dan strand konsisten. Nama `seqid` lokal `Pf3D7_11.v3` berbeda dari region Ensembl `LN999945.1`, sedangkan versi assembly tidak tersimpan secara eksplisit pada schema lokal.

Setelah baris disimpan, jalankan query berikut.

```
SELECT check_id, gene_id, external_gene_id, feature_type,
       seqid, start_pos, end_pos, strand, match_status
FROM mg07.repository_check
WHERE check_id = 'NIM_p07_check01';
```

Hasil yang benar memuat tepat satu baris. Contoh hasil pemeriksaan repositori ditunjukkan pada Gambar 17.

check_id	gene_id	external_gene_id	feature_type	seqid	start_pos	end_pos	strand	match_status
NIM_p07_check01	PF3D7_1145400	PF3D7_1145400	protein_coding_gene	LN999945.1	1800111	1804509	-	sesuai

Gambar 17. Hasil pemeriksaan repositori yang tersimpan pada `mg07.repository_check`.

7.4 Menguji Hubungan dengan Data Lokal

Jalankan tiga query berikut secara terpisah. Query pertama membuktikan bahwa gen lokal terhubung dengan satu rekaman pencarian dan hit yang dicatat.

```
SELECT g.gene_id, r.run_id, r.query_accession,
       r.target_database, r.result_origin,
       h.hit_rank, h.hit_accession,
       h.percent_identity, h.query_cover,
       CASE WHEN h.evalue = 0 THEN '0.0'
            ELSE TRIM(TO_CHAR(h.evalue, '9.99EEEE'))
       END AS evalue
FROM public.gene AS g
JOIN mg07.search_run AS r
  ON r.gene_id = g.gene_id
LEFT JOIN mg07.search_hit AS h
  ON h.run_id = r.run_id
WHERE r.run_id = 'NIM_p07_01'
ORDER BY h.hit_rank;
```

Contoh yang diuji menghasilkan dua baris seperti pada Gambar 18. Satu `gene_id` muncul pada dua baris karena satu rekaman pencarian terhubung dengan dua hit BLASTP.

Data Output Messages Notifications									
Showing rows: 1 to 2									
	gene_id text	run_id text	query_accession text	target_database text	result_origin text	hit_rank integer	hit_accession text	percent_identity numeric	query_cover numeric
1	PF3D7_1145400	NIM_p07_01	PF3D7_1145400.1-p1	refseq_protein	mandiri	1	XP_001348132...	100.00	100
2	PF3D7_1145400	NIM_p07_01	PF3D7_1145400.1-p1	refseq_protein	mandiri	2	XP_001347652...	29.92	83

Gambar 18. Hasil JOIN gen lokal, rekaman pencarian, dan hit BLASTP.

Query kedua menghitung banyak hit yang benar-benar dicatat pada tabel, bukan seluruh homolog yang mungkin ada.

```
SELECT r.run_id, r.gene_id,
       COUNT(h.hit_rank) AS jumlah_hit_dicatat
FROM mg07.search_run AS r
LEFT JOIN mg07.search_hit AS h
      ON h.run_id = r.run_id
WHERE r.run_id = 'NIM_p07_01'
GROUP BY r.run_id, r.gene_id;
```

Pada hasil contoh, `jumlah_hit_dicatat` bernilai 2 seperti pada Gambar 19.

Data Output Messages Notifications			
Showing rows: 1 to 1			
	run_id [PK] text	gene_id text	jumlah_hit_dicatat bigint
1	NIM_p07_01	PF3D7_1145400	2

Gambar 19. Jumlah hit BLASTP yang dicatat untuk satu kegiatan pencarian.

Query ketiga menghubungkan gen lokal dengan kesimpulan pemeriksaan repositori.

```
SELECT g.gene_id, c.external_gene_id, c.feature_type,
       c.assembly_note, c.match_status, c.note
FROM public.gene AS g
JOIN mg07.repository_check AS c
      ON c.gene_id = g.gene_id
WHERE c.check_id = 'NIM_p07_check01';
```

Query ketiga harus menghasilkan satu baris seperti pada Gambar 20.

Data Output Messages Notifications						
Showing rows: 1 to 1						
	gene_id text	external_gene_id text	feature_type text	assembly_note text	match_status text	note text
1	PF3D7_1145400	PF3D7_1145400	protein_coding_gene	Ensembl GCA_000002765.3; rilis 2026...	sesuai	Identifler, jenis fitur, koordinat 1800111-

Gambar 20. Hasil JOIN gen lokal dan pemeriksaan repositori Ensembl.

Pada data contoh, `match_status` bernilai `sesuai`. Dengan demikian, hubungan yang diuji adalah `public.gene` ke `mg07.search_run` melalui `gene_id`, `search_run` ke `search_hit` melalui `run_id`, dan `public.gene` ke `mg07.repository_check` melalui `gene_id`.

Titik Pemeriksaan

Pastikan schema *mg07* memuat tiga tabel, satu *run* BLASTP, hit yang dipilih, dan satu pemeriksaan repositori. Ketiga query integrasi harus menghasilkan data.

8 Lembar Kerja Praktikum (LKP)

LKP mendokumentasikan penelusuran PF3D7_1145400 dan *identifier* kedua pada kegiatan kolaboratif. Setiap mahasiswa menyusun laporan dengan identitasnya masing-masing dan mencantumkan nama rekan praktikum. Tuliskan hasil yang benar-benar diamati.

8.1 Penelusuran Kolaboratif

Gunakan PF3D7_1222300 sebagai *identifier* kedua. Ulangi alur pemeriksaan lokal, penelusuran rekaman, pengambilan FASTA, pencarian BLASTP, pemeriksaan *genome browser*, penyimpanan pada schema *mg07*, dan pengujian JOIN yang telah dilakukan pada bagian sebelumnya.

1. Jalankan kembali query fitur lokal pada Subbagian 3.2 menggunakan PF3D7_1222300. Untuk melengkapi lembar pengamatan, periksa pula satu anotasi lokal menggunakan query anotasi lokal pada Subbagian 3.3.
2. Telusuri rekaman sumber dan catat bukti hubungan gen, transkrip, dan protein. Ambil FASTA protein hanya setelah hubungan tersebut terverifikasi.
3. Ulangi BLASTP dan pemeriksaan *genome browser*. Gunakan NIM_p07_02 sebagai *run_id* dan NIM_p07_check02 sebagai *check_id*. Ganti NIM dengan NIM masing-masing.
4. Jalankan ketiga query integrasi pada Subbagian 7.4 untuk data *identifier* kedua, kemudian isi lembar pengamatan berdasarkan hasil yang benar-benar diperoleh.
5. Bertukar peran: satu mahasiswa menjelaskan bukti pemetaan *identifier*, sedangkan rekan praktikumnya memeriksa sumber, pencatatan, dan hasil JOIN. Setelah itu, tukarkan peran.

8.2 Pertanyaan Pembahasan

Jawab pertanyaan berikut berdasarkan hasil penelusuran yang paling relevan dari *identifier* pertama atau kedua. Tidak perlu menyusun jawaban terpisah untuk setiap *identifier*.

1. Apa bukti bahwa protein *query* terkait dengan *identifier* lokal? Sebutkan halaman atau *cross-reference* yang mendukung.
2. Bandingkan *percent identity* dan *query cover* hit yang dicatat. Apakah kemiripannya mencakup sebagian besar *query* atau hanya bagian tertentu?
3. Apakah fitur genomik lokal dan daring sesuai? Jika berbeda atau belum terverifikasi, jelaskan bagian yang masih perlu diperiksa.
4. Mengapa jumlah baris hasil JOIN tidak selalu sama dengan jumlah *identifier* gen? Gunakan salah satu hasil query integrasi pada Subbagian 7.4 sebagai contoh.
5. Informasi apa yang diperlukan agar pencarian dapat diulangi? Apa yang masih mungkin berubah meskipun parameter pencariannya sama?

8.3 Struktur, Format, dan Pengumpulan LKP

Susun LKP individual sepanjang 3–5 halaman di luar lampiran dengan urutan berikut. Tidak diperlukan halaman sampul terpisah.

1. **Judul dan identitas.** Cantumkan judul praktikum, nama, NIM, nama rekan praktikum, tanggal, dan nama database pada bagian awal halaman pertama.
2. **Tujuan.** Tuliskan tujuan praktikum secara ringkas.
3. **Hasil penelusuran.** Buat dua subbagian, yaitu hasil PF3D7_1145400 dan hasil PF3D7_1222300. Pada setiap subbagian, tampilkan lembar pengamatan dan ringkasan hit BLASTP.
4. **Pembahasan.** Jawab lima pertanyaan pada Subbagian 8.2 satu kali dengan menggunakan hasil yang paling relevan dari salah satu atau kedua *identifier*.
5. **Kesimpulan.** Ringkas hasil utama dan bedakan hasil pengamatan dari interpretasi.
6. **Sumber.** Cantumkan halaman daring yang digunakan beserta tanggal aksesnya.
7. **Lampiran.** Sertakan tangkapan layar atau keluaran tambahan yang diperlukan sebagai bukti pendukung.

Gunakan format lembar pengamatan pada Tabel 8. Buat dan isi tabel tersebut dua kali, masing-masing untuk PF3D7_1145400 dan PF3D7_1222300.

Tabel 8. Format lembar pengamatan untuk setiap *identifier*.

Kelompok data	Informasi yang dicatat	Hasil pengamatan
Identitas penelusuran	<i>Identifier</i> , <i>run_id</i> , tanggal, dan nama database.	
Rekaman lokal	<i>gene_id</i> , jenis fitur, <i>seqid</i> , <i>start_pos</i> , <i>end_pos</i> , <i>strand</i> , dan satu anotasi bila tersedia.	
Sumber query	Repositori, URL, <i>identifier</i> gen, transkrip, dan protein, versi bila tersedia, panjang protein, tanggal akses, serta nama berkas FASTA.	
Pencarian BLAST	Program, database target, filter organisme, parameter, waktu pencarian, RID, nama berkas hasil, dan <i>result_origin</i> bernilai <i>mandiri</i> .	
Genome browser	Assembly atau rilis, jenis fitur, kromosom atau region, koordinat, <i>strand</i> , URL, tanggal akses, status kecocokan, dan alasan penetapan status.	

Setelah setiap lembar pengamatan, tambahkan ringkasan hit menggunakan format pada Tabel 9. Gunakan satu baris untuk setiap protein yang dicatat dari tab **Descriptions**, bukan satu baris untuk setiap HSP pada berkas CSV.

Tabel 9. Format ringkasan hit BLASTP untuk setiap *identifier*.

Rank	Accession	Deskripsi	Organisme	Identity	Cover	E-value	Max score
------	-----------	-----------	-----------	----------	-------	---------	-----------

Kolom **Identity** diisi dengan *percent identity*, sedangkan kolom **Cover** diisi dengan *query cover*. Simpan laporan sebagai NIM_nama_p07.pdf. Kumpulkan pula berkas NIM_nama_p07.zip yang memuat naskah SQL, FASTA, catatan sumber, hasil BLASTP, tangkapan layar yang relevan, dan hasil query.